# 모듈 1: 책임 있는 AI 기초

Generative AI Essentials with AWS (한국어)



© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 모듈 목표



이 모듈에서 학습할 내용은 다음과 같습니다.

- 책임 있는 AI의 8가지 핵심 요소를 각각 설명
- 책임 있는 AI 원칙에 대한 AWS의 노력을 설명

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# AI의 진화: 기존 방식에서 생성형으로

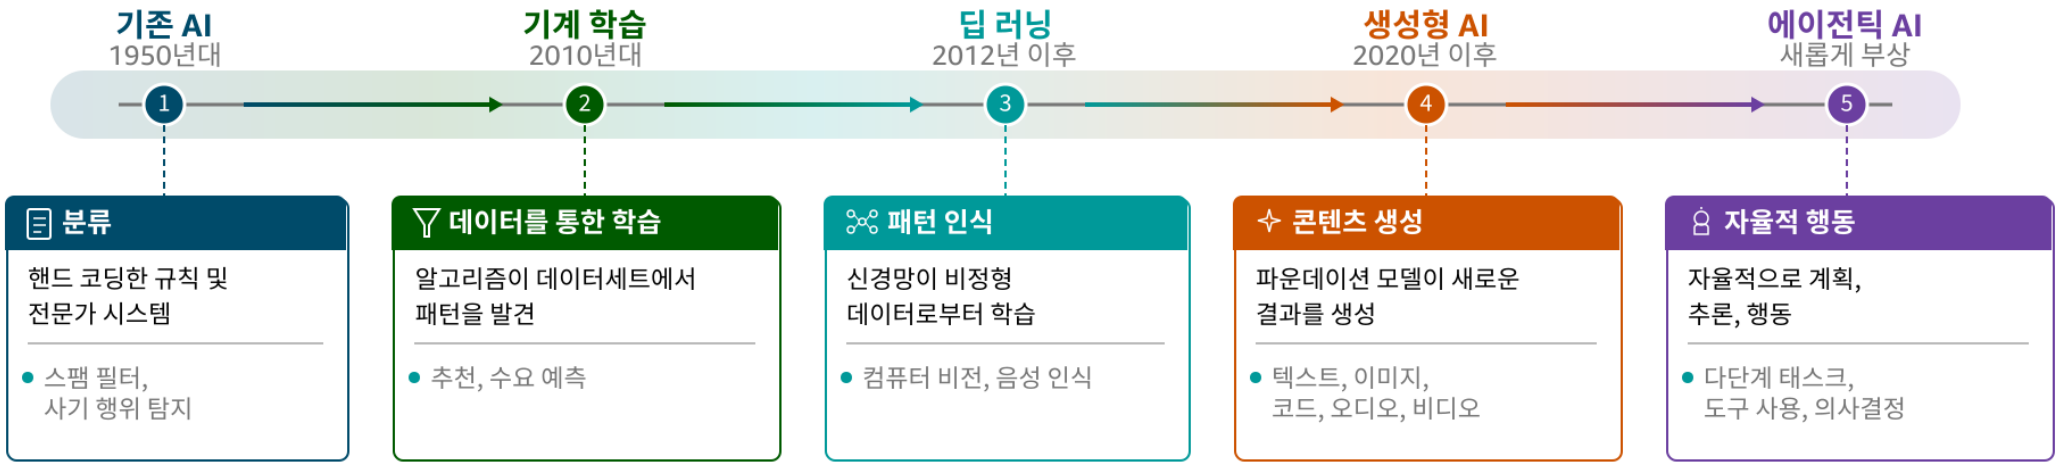
Generative AI Essentials with AWS



© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# AI 진화의 시대

각 시대는 이전 시대의 기능을 기반으로 확장합니다.




© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 책임 있는 AI의 8가지 차원

책임 있는 AI 기초



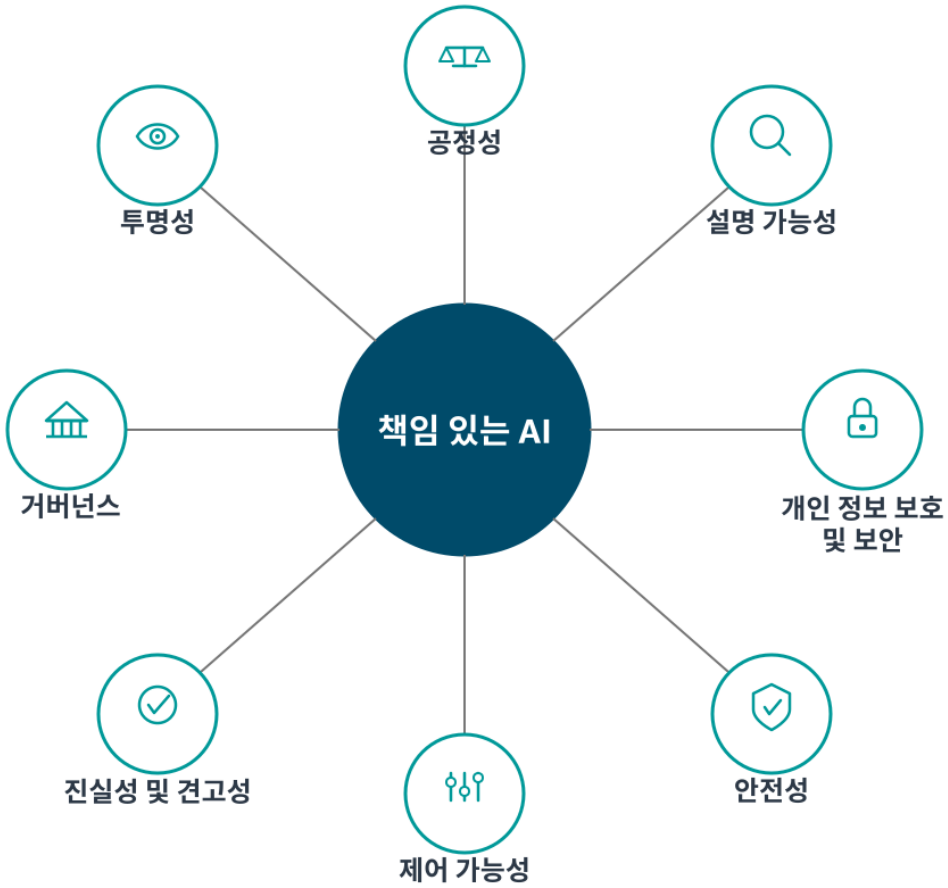
© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 책임 있는 AI의 8가지 차원에 대한 소개

## 책임 있는 AI란?

**"책임 있는 AI란 이점을 극대화하고 위험을 최소화하는 것을 목표로 AI 기술을 설계, 개발, 사용하는 원칙입니다."**

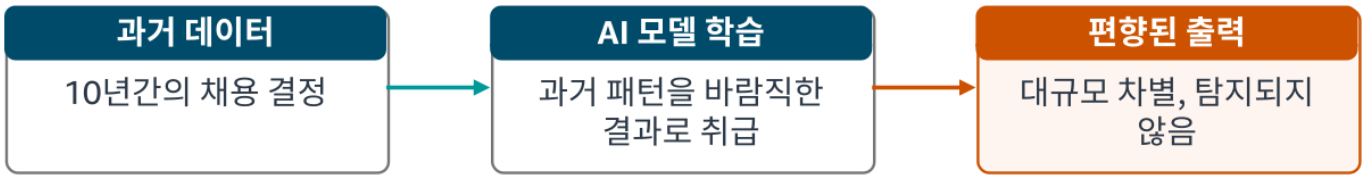
출처: Responsible AI Lens AWS Well-Architected Framework




© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 공정성 - 편견 및 차별 피하기

**핵심 인사이트:** AI 편향은 의도적 설계가 아닌 훈련 데이터에서 비롯됩니다.




**예: 이력서 심사 도구**

시스템이 기술적으로는 올바른 것으로 보이지만 차별적인 결과를 생성함 - 데이터에 숨겨진 편향

**공정성은 일회성 확인이 아닙니다. 데이터가 변경되고 모델이 재훈련됨에 따라 지속적인 모니터링이 필요합니다.**

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 안전성 - 유해 출력 방지

생성형 AI는 새로운 안전 위험을 초래하며 신중하게 완화할 필요가 있습니다.

### ⚠ 위험

- **유해 콘텐츠**
  모욕적이거나 폭력적이거나 부적절한 콘텐츠
- **위험한 지침**
  유해한 활동에 대한 단계별 지침
- **잘못된 정보**
  사실인 것처럼 보이는 허위 진술(할루시네이션)

### [OK] 완화

- **콘텐츠 필터**
  배송 전 유해 물질에 대한 화면 출력
- **컨텍스트 근거**
  응답을 검증된 소스 자료에 근거를 두도록 함
- **인적 검토**
  고위험 출력에 대한 인적 감독

### ! 예: AI 할루시네이션

사용자가 AWS 서비스에 대해 질문하고 AI가 자신 있게 설명합니다. **"CloudSync pro"** 이 서비스는 **존재하지 않습니다.**

그럴듯하게 들리지만 완전히 조작된 정보입니다. 답변은 조작된 가격과 기능으로 채워져 있습니다. 이는 잘못된 결정으로 이어질 수 있습니다.

**문제 해결:** 사용 **컨텍스트 근거** - AI 응답을 검증된 소스 문서에 근거를 두도록 함으로써 할루시네이션 출력을 감지 및 방지합니다.

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 개인 정보 보호 및 보안, 제어 가능성

**안전한 AI에는 강력한 데이터 보호가 필요하고, 제어 가능한 AI에는 인적 감독이 필요합니다.**

## 개인 정보 보호 및 보안

### 데이터 암호화
저장 및 전송 데이터 보호

### 액세스 제어
사용자의 권한을 세분화

### 데이터 최소화
필요한 데이터만 수집

### 개인 정보 보호 기법
차등 프라이버시, 익명화

## 제어 가능성

### 모니터링 대시보드
AI 동작 및 성능에 대한
실시간 가시성 제공

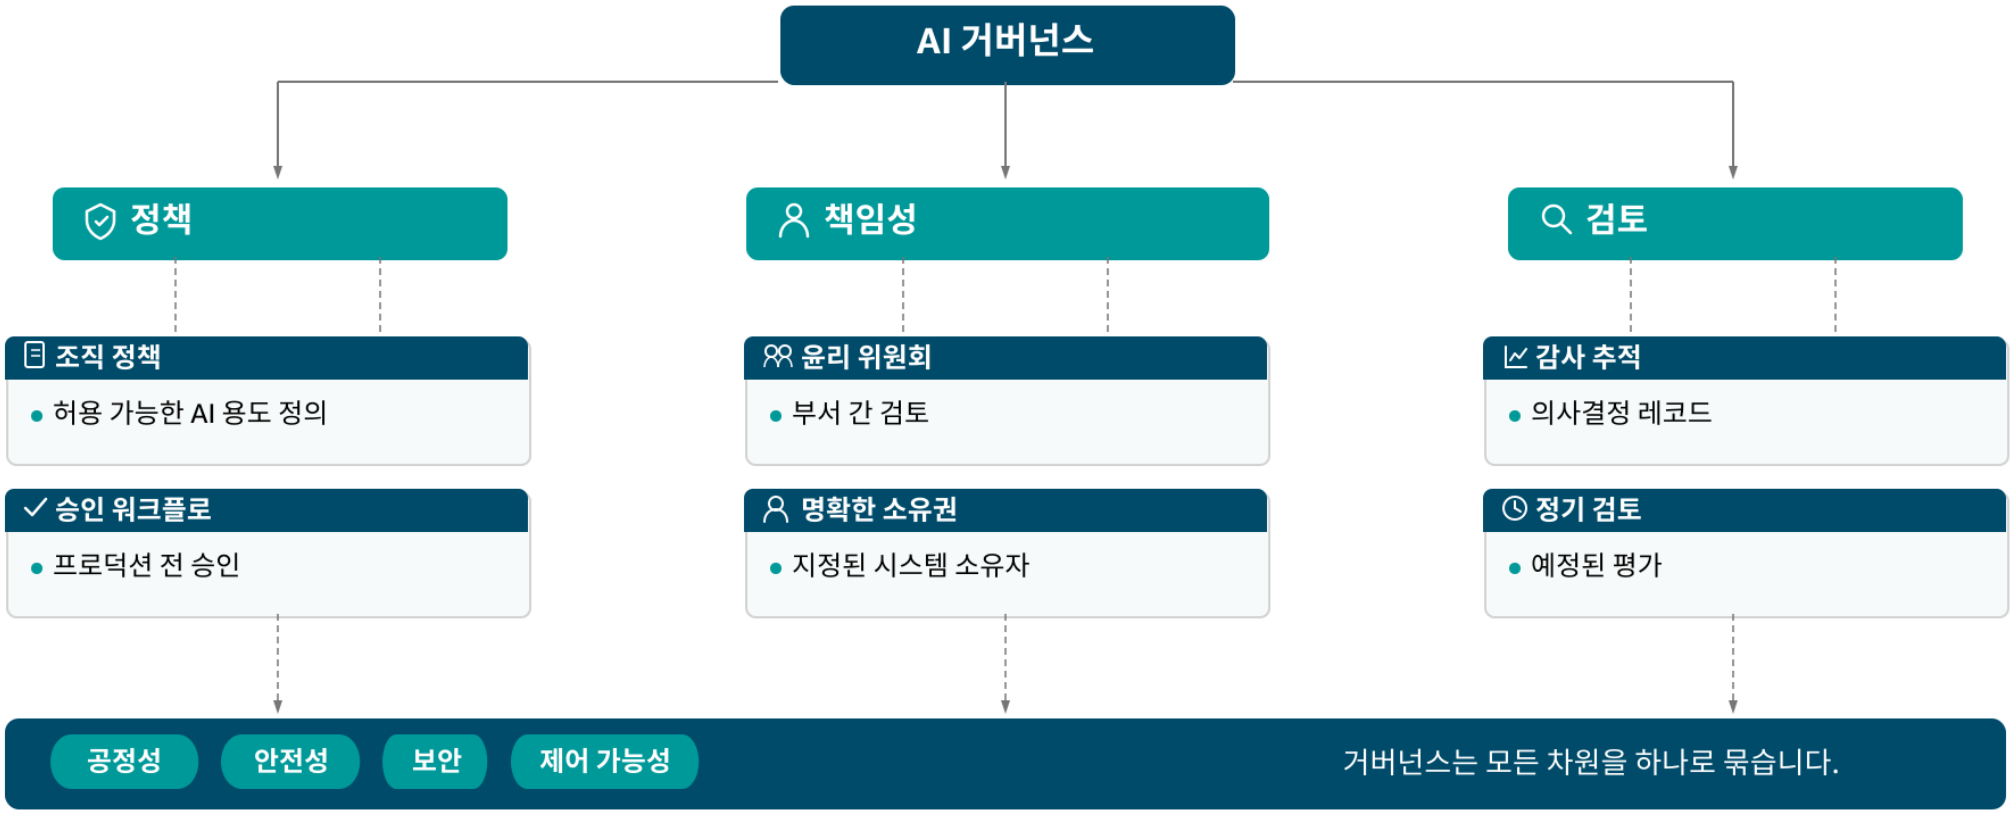
### 재정의 메커니즘
인간이 AI 동작을 수정, 리디렉션
또는 중단할 수 있습니다.

### 피드백 루프
수정 사항을 캡처하여
향후 시스템 성능을 개선합니다.

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 거버넌스 - 조직 차원의 책임

책임 있는 AI 원칙을 실행 가능한 조직 관행으로 전환




© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 설명 가능성, 투명성, 진실성 및 견고성

## 책임 있는 AI 프레임워크 완성

### 설명 가능성

**AI가 출력을 생성한 이유를 이해**

설명 가능성 스펙트럼




**예: 대출 거절**
'신용 이력 부족'
불투명한 거부가 아님

### 투명성

**AI 상호 작용에 대해 정보에 입각한 선택을 지원**

주요 관행

- AI 관여 공개
- 제한 사항 소통
- 명확한 기대치 설정

**예: AI 챗봇**
AI 기반인 것으로 식별,
지식의 한계를 인정

### 진실성 및 견고성

**적대적 입력에서도 신뢰할 수 있는 행동을 유지**

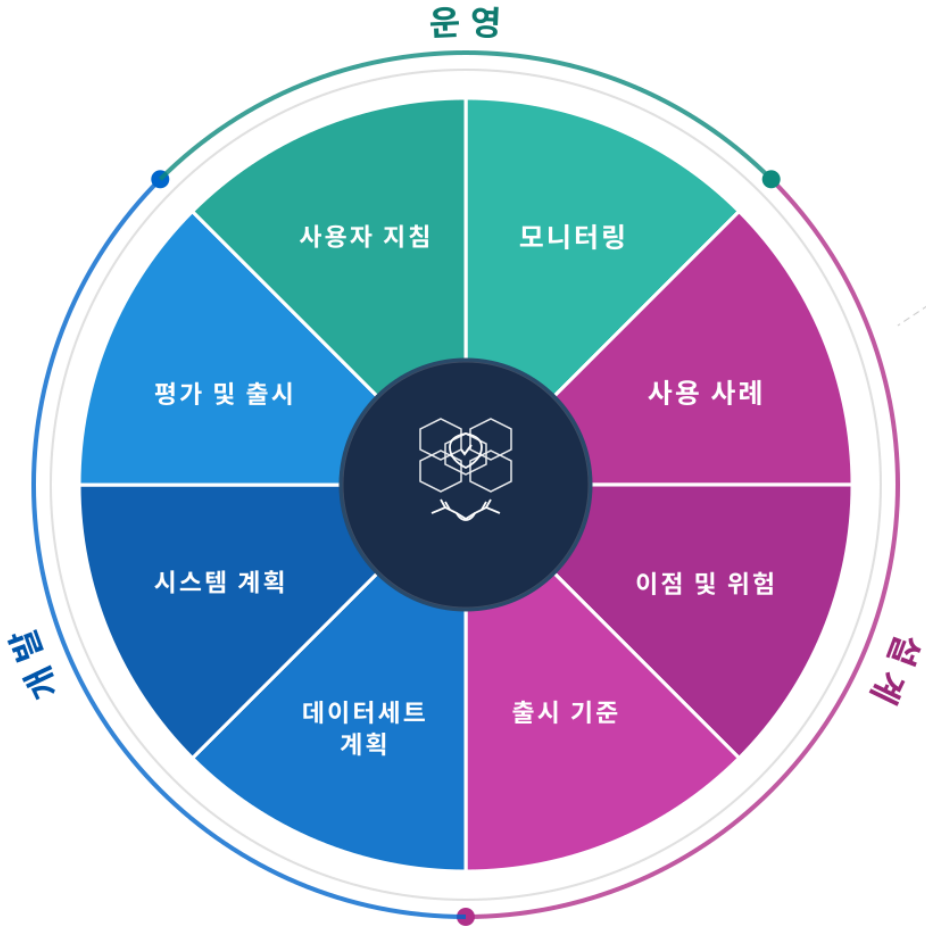
방어 접근 방식

- 적대적 사용 예측
- 사전 예방적 방어 설계
- 출력 정확성 검증

**예: 프롬프트 인젝션**
입력을 통한 안전 장치 우회,
사전 예방적 방어 필요

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# AI 시스템 수명 주기 전반의 책임 있는 AI




**Well-Architected Responsible AI Lens**

설계, 개발, 운영 전반에 걸친 실무 지침

- 신중한 설계 선택
- 신뢰할 수 있는 AI 배포

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 책임 있는 AI에 대한 AWS의 노력



© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# AWS 책임 있는 AI 원칙 및 도구

책임 있는 AI 구현의 각 단계를 위해 특별히 구축된 도구

### 편향 탐지 및 설명 가능성

**Amazon SageMaker Clarify**

- 훈련 데이터 및 모델의 편향 감지
- SHAP 기반 특성 설명

⚠ 편향을 감지 및 측정합니다(자동 수정은 하지 않음).

### 콘텐츠 안전 및 가드레일

**Guardrails for Amazon Bedrock**

- 콘텐츠 필터 및 금지 주제
- PII 삭제 및 근거 검사

모듈 5의 실습

### 모델 문서화

**SageMaker AI 모델 카드**

- 표준화된 모델 세부 정보 프레임워크
- 위험 등급, 사용 및 평가 정보

### 지속적 모니터링

**SageMaker AI Model Monitor**

- 데이터 품질 및 바이어스 드리프트를 추적
- 배포 후 책임을 강화

**도구는 다양한 차원을 다룹니다. 예를 들어 가드레일은 안전, 제어 가능성, 거버넌스를 함께 강화합니다.**

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 투명성 및 조직 차원 지원

## 투명성 관행

### AI 서비스 카드

- 사용 사례, 제한 사항, 설계 선택
- 서비스별로 공개적으로 사용 가능

**AI 서비스 카드 ≠ 모델 카드**

AWS에서 게시 및 자체 생성

## 조직 차원 지원

### 프레임워크 조정

NIST AI RMF　ISO/IEC 42001

- 서비스를 규정 준수 표준에 매핑

### AWS AI 준비 이니셔티브

- 무료 AI 기술 교육 프로그램

## 공동 책임

AWS 도구는 규정 준수를 지원하지만 이를 보장하지는 않습니다.

- 관련 규정 이해
- 모든 단계에서 지속적인 관심

**핵심 사항** | 투명성 문서화 + 프레임워크 조정 = 조직의 책임 있는 AI 프로그램

© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 지식 확인



© 2026, Amazon Web Services, Inc. 또는 계열사. All rights reserved

# 지식 확인 1

## 시나리오

다음 중 책임 있는 AI의 8가지 차원 간의 관계를 가장 잘 설명한 문장은 무엇입니까?

**A** 각 차원은 독립적으로 작동하며 개별적으로 구현할 수 있습니다.

**B** 안전성 차원이 가장 중요하므로 조직은 다른 모든 차원보다 안전성 차원을 우선시해야 합니다.

**C** 차원은 AI 수명 주기의 개발 단계에서만 적용됩니다.

**D** 8가지 차원이 모두 함께 작동해야 합니다. 단일 차원만으로는 충분하지 않습니다.

# 지식 확인 1 - 정답

## 시나리오

다음 중 책임 있는 AI의 8가지 차원 간의 관계를 가장 잘 설명한 문장은 무엇입니까?

A. 각 차원은 독립적으로 작동하며 개별적으로 구현할 수 있습니다.

B. 안전성 차원이 가장 중요하므로 조직은 다른 모든 차원보다 안전성 차원을 우선시해야 합니다.

C. 차원은 AI 수명 주기의 개발 단계에서만 적용됩니다.

D. 8가지 차원이 모두 함께 작동해야 합니다. 단일 차원만으로는 충분하지 않습니다. ✓

# 지식 확인 2

## 시나리오

모듈에 따르면, 기존 ML과 생성형 AI에서 공정성 편향 문제를 해결하는 데 필요한 접근 방식의 핵심적인 차이점은 무엇입니까?

**A** 기존 ML은 편향 심사를 위한 윤리 위원회가 필요하지만, 생성형 AI는 자체 수정 기능이 있기 때문에 그렇지 않습니다.

**B** 기존 ML 모델은 수학적 알고리즘을 사용하기 때문에 편향을 나타낼 수 없습니다.

**C** 기존 ML을 사용하면 조직이 훈련 데이터를 제어하고 탐지 및 완화 전략을 적용할 수 있습니다. 생성형 AI를 사용하면 파운데이션 모델이 조직에서 제어하지 못하는 대규모 데이터세트에서 훈련됩니다.

**D** 생성형 AI 모델은 다양한 인터넷 데이터를 기반으로 훈련되기 때문에 편향이 없습니다.

# 지식 확인 2 - 정답

## 시나리오

모듈에 따르면, 기존 ML과 생성형 AI에서 공정성 편향 문제를 해결하는 데 필요한 접근 방식의 핵심적인 차이점은 무엇입니까?

**A** 기존 ML은 편향 심사를 위한 윤리 위원회가 필요하지만, 생성형 AI는 자체 수정 기능이 있기 때문에 그렇지 않습니다.

**B** 기존 ML 모델은 수학적 알고리즘을 사용하기 때문에 편향을 나타낼 수 없습니다.

**C** 기존 ML을 사용하면 조직이 훈련 데이터를 제어하고 탐지 및 완화 전략을 적용할 수 있습니다. 생성형 AI를 사용하면 파운데이션 모델이 조직에서 제어하지 못하는 대규모 데이터세트에서 훈련됩니다. ✓

**D** 생성형 AI 모델은 다양한 인터넷 데이터를 기반으로 훈련되기 때문에 편향이 없습니다.